Московский государственный технический университет им. Н.Э. Баумана
Кафедра «Системы обработки информации и управления»

Лабораторная работа №2
по дисциплине
«Методы машинного обучения»
на тему

«Обработка признаков»

Выполнил:
студент группы ИУ5И-21М
Ли Лююй

Москва — 2024 г.

Цель лабораторной работы:

Изучение продвинутых способов предварительной обработки данных для дальнейшего формирования моделей.

Задание:

1. Выбрать набор данных (датасет), содержащий категориальные и числовые признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
2. Для выбранного датасета (датасетов) на основе материалов лекций решить следующие задачи:
    - устранение пропусков в данных;
    - кодирование категориальных признаков;
    - нормализацию числовых признаков.

Ход выполнения работы

1. Обработка пропусков в данных

Данные, которые я выбираю, - это то, как каждая страна в мире ежедневно вакцинируется против нового коронавируса.

In [1]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import sklearn.impute
import sklearn.preprocessing

pd.set_option("display.width",70)
data=pd.read_csv("covid19.csv")
data.head
```

Out[1]:
```
<bound method NDFrame.head of       country iso_code        date  total_vaccinations  \
0     Albania      ALB  2021-01-10                 0.0
1     Albania      ALB  2021-01-11                 NaN
2     Albania      ALB  2021-01-12               128.0
3     Albania      ALB  2021-01-13               188.0
4     Albania      ALB  2021-01-14               266.0
...       ...      ...         ...                 ...
3307    Wales      NaN  2021-02-11            719954.0
3308    Wales      NaN  2021-02-12            753669.0
3309    Wales      NaN  2021-02-13            776224.0
3310    Wales      NaN  2021-02-14            790211.0
3311    Wales      NaN  2021-02-15            803178.0

      people_vaccinated  people_fully_vaccinated  \
0                   0.0                      NaN
1                   NaN                      NaN
2                 128.0                      NaN
3                 188.0                      NaN
4                 266.0                      NaN
```

```
data.dtypes
```

```
country                                object
iso_code                               object
date                                   object
total_vaccinations                    float64
people_vaccinated                     float64
people_fully_vaccinated               float64
daily_vaccinations_raw                float64
daily_vaccinations                    float64
total_vaccinations_per_hundred        float64
people_vaccinated_per_hundred         float64
people_fully_vaccinated_per_hundred   float64
daily_vaccinations_per_million        float64
vaccines                               object
source_name                            object
source_website                         object
dtype: object
```

Найдем все пропуски в данных:

```
data.isnull().sum()    #Обработка пропусков в данных
```

```
country                                  0
iso_code                               260
date                                     0
total_vaccinations                    1167
people_vaccinated                     1538
people_fully_vaccinated               2175
daily_vaccinations_raw                1528
daily_vaccinations                     126
total_vaccinations_per_hundred        1167
people_vaccinated_per_hundred         1538
people_fully_vaccinated_per_hundred   2175
daily_vaccinations_per_million         126
vaccines                                 0
source_name                              0
source_website                           0
dtype: int64
```

Очевидно, что мы будем работать с колонкой ‘people_fully_vaccinated’ или ‘people_fully_vaccinated_per_hundred’. Я выбрал ‘people_fully_vaccinated_per_hundred’

Самый простой вариант — заполнить пропуски нулями:

```
sns.distplot(data['people_fully_vaccinated_per_hundred'].fillna(0));
```

```
/Users/ding/opt/anaconda3/lib/python3.8/site-packages/seaborn/distribut
eprecated function and will be removed in a future version. Please adap
level function with similar flexibility) or `histplot` (an axes-level f
  warnings.warn(msg, FutureWarning)
```

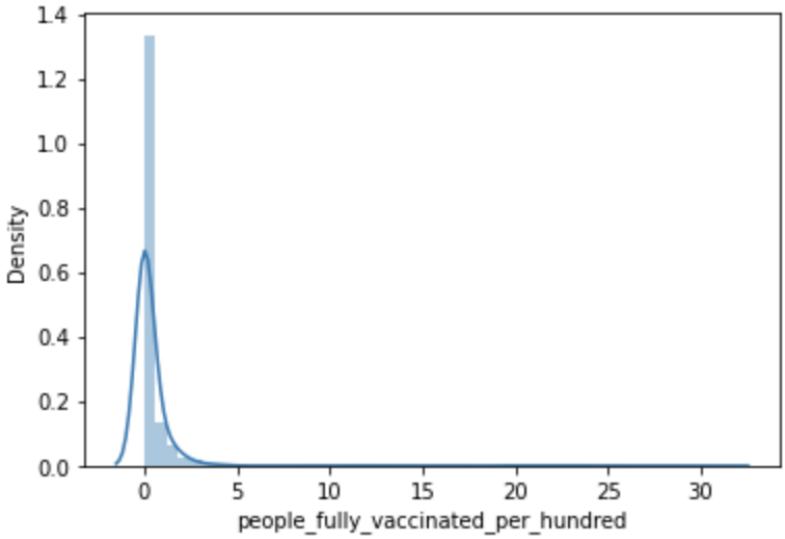

Видно, что в данной ситуации это приводит к выбросам. Логичнее было бы приложениям без данных присваивать средний:

```
mean_imp = sklearn.impute.SimpleImputer(strategy="mean")
mean_rat = mean_imp.fit_transform(data[["people_fully_vaccinated_per_hundred"]])
sns.distplot(mean_rat);
```

```
/Users/ding/opt/anaconda3/lib/python3.8/site-packages/seaborn/distributions.py:255
eprecated function and will be removed in a future version. Please adapt your code
level function with similar flexibility) or `histplot` (an axes-level function for
  warnings.warn(msg, FutureWarning)
```

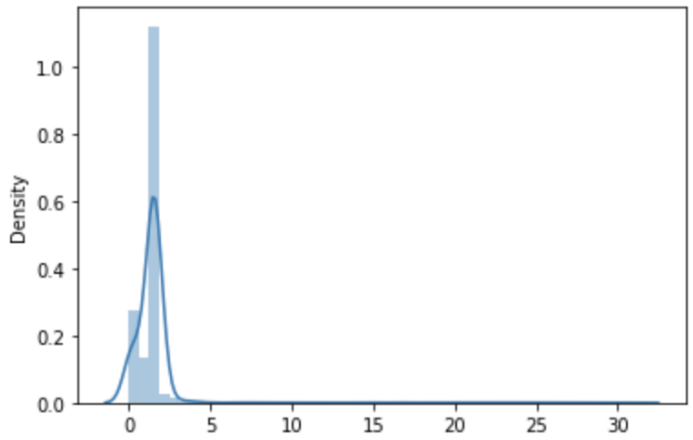

Попробуем также медианный и самые частые данные:

```
med_imp = sklearn.impute.SimpleImputer(strategy="median")
med_rat = med_imp.fit_transform(data[["people_fully_vaccinated_per_hundred"]])
sns.distplot(med_rat);
```

```
/Users/ding/opt/anaconda3/lib/python3.8/site-packages/seaborn/distributions.py:25
eprecated function and will be removed in a future version. Please adapt your cod
level function with similar flexibility) or `histplot` (an axes-level function fo
  warnings.warn(msg, FutureWarning)
```

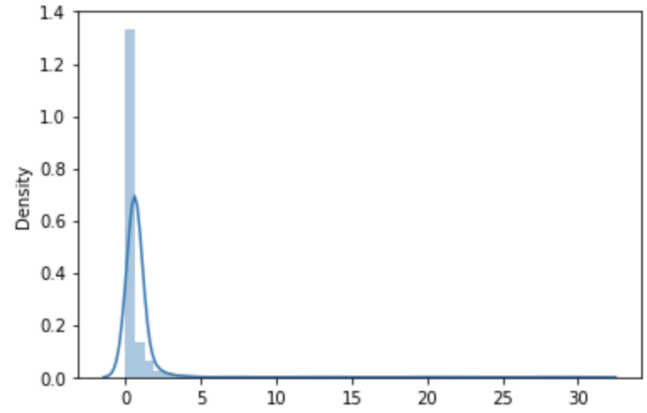

```
freq_imp = sklearn.impute.SimpleImputer(strategy="most_frequent")
freq_rat = freq_imp.fit_transform(data[["people_fully_vaccinated_per_hundred"]])
sns.distplot(freq_rat);
```

```
/Users/ding/opt/anaconda3/lib/python3.8/site-packages/seaborn/distributions.py:255
eprecated function and will be removed in a future version. Please adapt your code
level function with similar flexibility) or `histplot` (an axes-level function for
  warnings.warn(msg, FutureWarning)
```

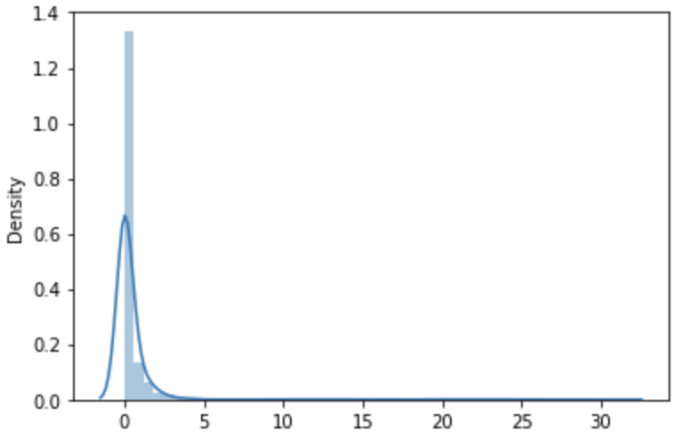

Видно, что самый близкий к нормальному распределению график дало обычное среднее значение. Остановимся на нём:

```
data["people_fully_vaccinated_per_hundred"] = mean_rat
```

2. Кодирование категориальных признаков

Рассмотрим колонку ‘vaccines’:

```
data["people_fully_vaccinated_per_hundred"] = mean_rat
```

```
vaccines1 = data["vaccines"].dropna().astype(str)  #Кодирование категориальных признаков
vaccines1.value_counts()
```

```
Moderna, Oxford/AstraZeneca, Pfizer/BioNTech                                          970
Pfizer/BioNTech                                                                       771
Oxford/AstraZeneca, Pfizer/BioNTech                                                   521
Moderna, Pfizer/BioNTech                                                              327
Sputnik V                                                                             127
Oxford/AstraZeneca                                                                     99
Sinovac                                                                                71
Pfizer/BioNTech, Sinovac                                                               64
Sinopharm/Beijing, Sinopharm/Wuhan, Sinovac                                            57
Pfizer/BioNTech, Sinopharm/Beijing                                                     56
Oxford/AstraZeneca, Sinopharm/Beijing                                                  56
Oxford/AstraZeneca, Pfizer/BioNTech, Sinopharm/Beijing, Sinopharm/Wuhan, Sputnik V     43
Pfizer/BioNTech, Sinopharm/Beijing, Sputnik V                                          38
Covaxin, Oxford/AstraZeneca                                                            33
Oxford/AstraZeneca, Sinovac                                                            32
Oxford/AstraZeneca, Sputnik V                                                          21
Sinopharm/Beijing                                                                      17
Oxford/AstraZeneca, Sinopharm/Beijing, Sputnik V                                        9
Name: vaccines, dtype: int64
```

Выполним кодирование категорий целочисленными значениями:

```
 le = sklearn.preprocessing.LabelEncoder()
vaccines1_le = le.fit_transform(vaccines1)
print(np.unique(vaccines1_le))
le.inverse_transform(np.unique(vaccines1_le))
```

```
[ 0  1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17]
```

```
array(['Covaxin, Oxford/AstraZeneca',
       'Moderna, Oxford/AstraZeneca, Pfizer/BioNTech',
       'Moderna, Pfizer/BioNTech', 'Oxford/AstraZeneca',
       'Oxford/AstraZeneca, Pfizer/BioNTech',
       'Oxford/AstraZeneca, Pfizer/BioNTech, Sinopharm/Beijing, Sinopharm/Wuhan, Sputnik V',
       'Oxford/AstraZeneca, Sinopharm/Beijing',
       'Oxford/AstraZeneca, Sinopharm/Beijing, Sputnik V',
       'Oxford/AstraZeneca, Sinovac', 'Oxford/AstraZeneca, Sputnik V',
       'Pfizer/BioNTech', 'Pfizer/BioNTech, Sinopharm/Beijing',
       'Pfizer/BioNTech, Sinopharm/Beijing, Sputnik V',
       'Pfizer/BioNTech, Sinovac', 'Sinopharm/Beijing',
       'Sinopharm/Beijing, Sinopharm/Wuhan, Sinovac', 'Sinovac',
       'Sputnik V'], dtype=object)
```

Выполним кодирование категорий наборами бинарных значений:

```
vaccines_oh = pd.get_dummies(vaccines1)
vaccines_oh.head()
```

l/AstraZeneca, izer/BioNTech, pharm/Beijing, pharm/Wuhan, Sputnik V	Oxford/AstraZeneca, Sinopharm/Beijing	Oxford/AstraZeneca, Sinopharm/Beijing, Sputnik V	Oxford/AstraZeneca, Sinovac	Oxford/AstraZeneca, Sputnik V	Pfizer/BioNTech	Pfizer/BioNTech, Sinopharm/Beijing	Pfizer/BioNTech, Sinopharm/Beijing, Sputnik V	P
0	0	0	0	0	1	0	0	
0	0	0	0	0	1	0	0	
0	0	0	0	0	1	0	0	
0	0	0	0	0	1	0	0	
0	0	0	0	0	1	0	0	

```
vaccines_oh[vaccines_oh["Sputnik V"] == 1].head()
```

aZeneca, Sinovac	Oxford/AstraZeneca, Sputnik V	Pfizer/BioNTech	Pfizer/BioNTech, Sinopharm/Beijing	Pfizer/BioNTech, Sinopharm/Beijing, Sputnik V	Pfizer/BioNTech, Sinovac	Sinopharm/Beijing	Sinopharm/Beijing, Sinopharm/Wuhan, Sinovac	Sinovac	Sputnik V
0	0	0	0	0	0	0	0	0	1
0	0	0	0	0	0	0	0	0	1
0	0	0	0	0	0	0	0	0	1
0	0	0	0	0	0	0	0	0	1
0	0	0	0	0	0	0	0	0	1

3. **Масштабирование данных**

Для начала попробуем обычное MinMax-масштабирование:

```
mm = sklearn.preprocessing.MinMaxScaler()     # Масштабирование данных
sns.distplot(mm.fit_transform(data[["people_fully_vaccinated_per_hundred"]]));
```

```
/Users/ding/opt/anaconda3/lib/python3.8/site-packages/seaborn/distributions.py:2
eprecated function and will be removed in a future version. Please adapt your co
level function with similar flexibility) or `histplot` (an axes-level function f
  warnings.warn(msg, FutureWarning)
```

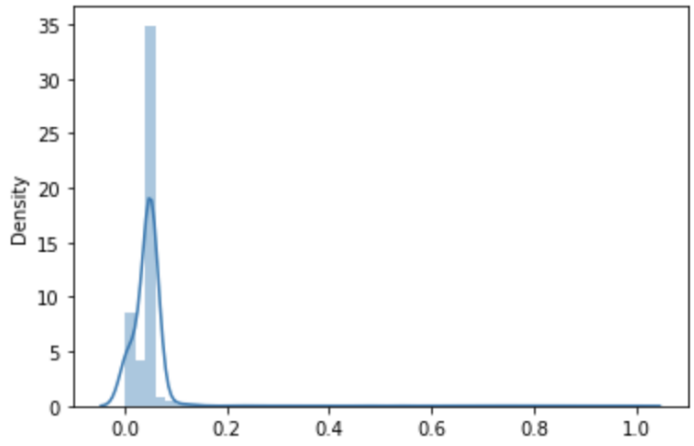

Результат вполне ожидаемый и вполне приемлемый. Но попробуем и другие варианты, например, масштабирование на основе Z-оценки:

```
ss = sklearn.preprocessing.StandardScaler()
sns.distplot(ss.fit_transform(data[["people_fully_vaccinated_per_hundred"]]));
```

```
/Users/ding/opt/anaconda3/lib/python3.8/site-packages/seaborn/distributions.py:
eprecated function and will be removed in a future version. Please adapt your c
level function with similar flexibility) or `histplot` (an axes-level function
  warnings.warn(msg, FutureWarning)
```

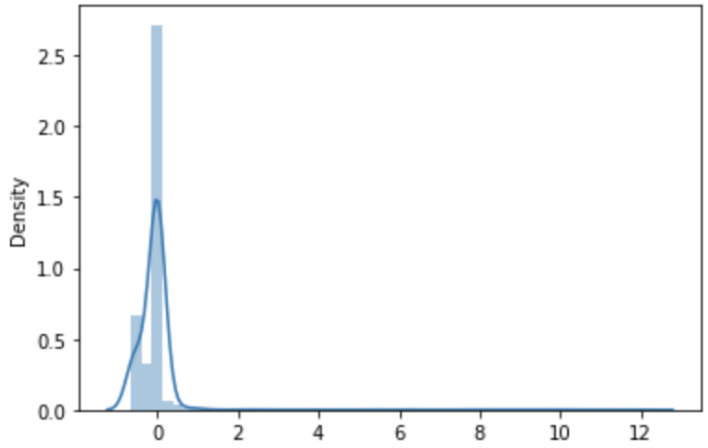

Также результат ожидаемый, но его применимость зависит от дальнейшего использования.

Список литературы

[1] Гапанюк Ю. Е. Лабораторная работа «Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных» [Электронный ресурс] // GitHub. — 2019. — Режим доступа: https://github.com/ugapanyuk/ml_course/wiki/LAB_MISSING (дата обращения: 05.04.2019).

[2] Team The IPython Development. IPython 7.3.0 Documentation [Electronic resource]//Read the Docs. — 2019. — Access mode: https://ipython.readthedocs.io/en/stable/ (online; accessed: 20.02.2019).

[3] Waskom M. seaborn 0.9.0 documentation [Electronic resource] // PyData. — 2018. — Access mode: https://seaborn.pydata.org/ (online; accessed: 20.02.2019).

[4] pandas 0.24.1 documentation [Electronic resource] // PyData. — 2019. — Access mode: http://pandas.pydata.org/pandas-docs/stable/ (online; accessed: 20.02.2019).
[5] Gupta L. Google Play Store Apps [Electronic resource] // Kaggle. — 2019. — Access mode: https://www.kaggle.com/lava18/google-play-store-apps (online; accessed:05.04.2019).